

HEALTHAI COACH

Rapport Technique

Conception et Implementation de la Base de Donnees Relationnelle

Projet	HealthAI Coach - MSPR Bloc E6.1
Formation	Developpeur IA - 3eme annee - EPSI Grenoble
Role	Conception et implementation de la base de donnees relationnelle
Auteure	Hanane AGHAZAF
Annee	2025 - 2026

1. Introduction

Dans le cadre de la MSPR Bloc E6.1, notre equipe a ete chargee de concevoir et de developper le backend metier de la plateforme HealthAI Coach, une startup specialisee dans le coaching sante personnalise base sur la donnee.

Au sein de cette equipe, ma mission a porte exclusivement sur la conception et l'implementation de la base de donnees relationnelle : la modelisation des donnees, la redaction des scripts SQL, l'automatisation de l'initialisation et le pipeline ETL permettant de charger les donnees depuis les fichiers CSV fournis.

Ce rapport presente les choix techniques effectues, les sources de donnees utilisees, l'architecture de la base de donnees et les validations realisees pour garantir la qualite des donnees.

2. Sources de Donnees

Conformement au cahier des charges, quatre datasets publics issus de la plateforme Kaggle ont ete selectionnes et fournis au format CSV. Ces donnees couvrent l'ensemble des besoins exprimes par HealthAI Coach.

2.1 Datasets utilises

Dataset	Tables alimentees	Contenu
Daily Food & Nutrition Dataset	foods, nutrition_logs	Aliments, valeurs nutritionnelles, type de repas
Gym Members Exercise Dataset	users, biometrics, activity_logs	Profils utilisateurs, donnees biometriques, seances
Gym Members Synthetic Dataset	users, biometrics, activity_logs	Donnees complementaires pour enrichir le volume
Diet Recommendations Dataset	health_profiles, user_goals	Profils sante, maladies, recommandations alimentaires

2.2 Justification des choix

Ces datasets ont ete retenus car ils couvrent precisement les quatre domaines de donnees requis par le cahier des charges : les profils utilisateurs, la base nutritionnelle, le catalogue d'activites physiques et les metriques de sante. Ils sont disponibles en open data, au format CSV, et presentent une structure coherente permettant une integration directe dans le modele relationnel defini.

Les donnees ont ete prealablement nettoyees par le membre de l'equipe responsable de la preparation des donnees, avant d'etre chargees dans la base via le pipeline ETL.

3. Conception du Modele de Donnees

La base de donnees relationnelle healthai_coach a ete concue pour repondre aux besoins fonctionnels de la plateforme tout en anticipant les futurs modules d'intelligence artificielle.

Elle repose sur 8 tables interconnectees, implementees sous MariaDB avec le moteur InnoDB.

3.1 Les 8 tables et leur role

Table	Role dans le modele
users	Stocke les informations de base de chaque utilisateur : age, genre, poids, taille, niveau de fitness et consommation d'eau.
biometrics	Contient les mesures physiques horodatees : BMI, frequence cardiaque, pourcentage de masse grasse. Separee de users pour permettre un suivi dans le temps.
foods	Reference complete des aliments avec leurs valeurs nutritionnelles : calories, proteines, glucides, lipides, fibres, sodium.
exercises	Catalogue des types d'exercices pratiques : cardio, musculation, yoga. Sert de reference pour les activity_logs.
health_profiles	Donnees medicales et dietetiques de l'utilisateur : type de maladie, cholesterol, glycemie, pression arterielle, recommandation alimentaire. Deliberement separee de users pour isoler les donnees sensibles.
user_goals	Objectifs de sante de l'utilisateur : perte de poids, prise de masse, maintien. La relation avec users est optionnelle par conception : un utilisateur peut exister sans objectif defini.
activity_logs	Journal des seances d'activite physique : duree, calories brulees, type d'exercice. Chaque seance est rattachee a un utilisateur et a un exercice.
nutrition_logs	Journal alimentaire : aliment consomme, type de repas, quantite. Relie chaque utilisateur a un aliment de la table foods.

3.2 Decisions de conception

Plusieurs choix techniques ont guide la conception du schema :

- **Separation de health_profiles et users** : les donnees medicales sont sensibles et evoluent independamment du profil de base. Cette separation facilite la gestion des droits d'accès et prepare l'integration de futurs modules IA specialises en sante.
- **ON DELETE CASCADE** : lorsqu'un utilisateur est supprime, toutes ses donnees associees (biometrics, activity_logs, nutrition_logs, etc.) sont automatiquement supprimees. Cela garantit l'integrite referentielle sans intervention manuelle.
- **Utilisation des ENUMs** : les champs a valeurs fixes (genre, niveau_fitness, type_objectif, repas) utilisent des ENUMs pour contraindre les valeurs acceptees et eviter les erreurs d'insertion.
- **Moteur InnoDB** : choisi pour son support natif des cles etrangeres et des transactions ACID, indispensables pour garantir la coherence des donnees dans un contexte multi-tables.
- **Relation optionnelle user_goals** : un utilisateur peut exister sans objectif defini, ce qui correspond au comportement reel de l'application ou l'objectif est renseigne progressivement.

4. Pipeline ETL

Le pipeline ETL (Extract, Transform, Load) est le processus qui permet de charger automatiquement les données depuis les fichiers CSV vers la base de données. Il a été entièrement développé en Node.js.

4.1 Architecture du pipeline

Le pipeline se compose de plusieurs scripts indépendants :

- **schema.sql** : contient la définition complète des 8 tables. Ce fichier est la référence pour recréer la base de données dans n'importe quel environnement.
- **init_db.js** : lit et exécute automatiquement le fichier schema.sql au démarrage. La base de données et toutes les tables sont créées sans intervention manuelle.
- **db.js** : gère la connexion à MariaDB via un pool de connexions. Le pool permet de réutiliser les connexions existantes plutôt qu'en créer une nouvelle à chaque requête.
- **service.js** : contient les 5 fonctions de chargement des données. Chaque fonction correspond à une étape du pipeline et prend en entrée un fichier CSV.
- **lancer_bdd.js** : script indépendant qui orchestre l'ensemble du pipeline en une seule commande, sans nécessiter le démarrage du serveur backend.

4.2 Étapes du pipeline

Étape	Fonction	Description
1 / 5	insertarFoods	Charge les aliments depuis daily_food_nutrition_bdd.csv. Traduit les types de repas (Breakfast -> petit_dejeuner).
2 / 5	insertarUsers	Charge les utilisateurs et leurs biométries depuis les deux fichiers gym_members. Génère un email unique par utilisateur.
3 / 5	insertarUserGoals	Charge les profils santé et les objectifs depuis diet_recommendations_bdd.csv. Mappe les recommandations vers les types d'objectifs.
4 / 5	insertarActivity	Charge les exercices uniques puis les séances d'activité de chaque utilisateur.
5 / 5	insertarNutritionLogs	Associe les aliments aux utilisateurs pour constituer leur journal alimentaire.

4.3 Lancement du pipeline

Le pipeline se lance avec une seule commande, indépendamment du serveur backend :

```
node lancer_bdd.js
```

5. Tests de Validation

Afin de valider le bon fonctionnement de la base de données, un document de tests a été produit. Il regroupe 10 requêtes SQL exécutées dans phpMyAdmin, couvrant l'intégrité des

donnees, la coherence des relations entre tables et la qualite des valeurs inserees. Ce document est fourni en annexe.

Ces tests permettent de verifier que :

- les 8 tables contiennent bien des donnees apres execution du pipeline,
- les cles etrangeres ne presentent aucune violation (biometrics, activity_logs, nutrition_logs),
- les valeurs des champs ENUM sont conformes aux valeurs attendues,
- les donnees numeriques sont coherentes (calories positives, BMI dans une plage realiste),
- les champs obligatoires sont renseignes (aucun aliment sans nom, aucun email en double).

6. Conclusion

La base de donnees relationnelle healthai_coach constitue le socle technique sur lequel repose l'ensemble de la plateforme HealthAI Coach. Ses 8 tables couvrent tous les domaines de donnees requis par le cahier des charges : profils utilisateurs, biometrie, nutrition, activite physique et sante.

La conception a ete pensee pour etre evolutive : la separation des donnees medicales dans health_profiles, l'utilisation des relations optionnelles et la structure normalisee du schema facilitent l'integration future des modules d'intelligence artificielle de recommandation et de personnalisation prevus dans la roadmap de HealthAI Coach.

Le pipeline ETL automatise garantit la reproductibilite du deploiement : en une seule commande, la base de donnees est creee et chargee avec l'ensemble des donnees, sans intervention manuelle. Les tests de validation fournis en annexe permettent de confirmer la qualite et la coherence des donnees inserees.